

INFORME DE EVALUACIÓN TÉCNICA

Selección de tecnología de avatar conversacional para la plataforma Virtual Patient

*Metodología de búsqueda, matriz de criterios ponderada, pruebas exploratorias, análisis de viabilidad
sin presupuesto y recomendación*

Diego — Ingeniería de Sistemas y Computación, Universidad de los Andes

Agosto de 2026

Tabla de contenido

1. Introducción y contexto.....	3
2. Metodología de búsqueda y criterios de inclusión/exclusión.....	3
2.1 Estrategia de búsqueda.....	3
2.2 Criterios de inclusión.....	3
2.3 Criterios de exclusión.....	4
2.4 Universo de herramientas identificadas.....	4
3. Matriz de criterios ponderada.....	5
3.1 Definición de criterios y ponderación.....	5
3.2 Evaluación individual de cada alternativa.....	5
3.3 Resultado y ranking.....	10
4. Resultados de las pruebas exploratorias.....	10
4.1 Nota metodológica y alcance.....	10
4.2 Latencia reportada por proveedor.....	11
4.3 Modelo de costo estimado por entrevista.....	11
4.4 Protocolo de validación empírica recomendado.....	12
5. Análisis de viabilidad — escenario sin presupuesto para APIs de pago.....	12
5.1 Niveles gratuitos disponibles.....	12
5.2 Alternativa de código abierto autoalojada.....	13
5.3 Estimación de costo de cómputo para autoalojamiento.....	13
5.4 Oportunidades del contexto académico.....	14
5.5 Conclusión de viabilidad.....	14
6. Recomendación argumentada.....	15
6.1 Recomendación principal: Azure AI Speech Avatar / Voice Live.....	15
6.2 Alternativa comercial secundaria: Simli.....	15
6.3 Alternativa abierta de respaldo: MuseTalk autoalojado.....	15
6.4 Hoja de ruta sugerida.....	15
7. Adaptación arquitectónica para las alternativas finalistas.....	16
7.1 Azure AI Speech Avatar / Voice Live.....	16
7.2 Simli (Audio-to-Video API).....	18
7.3 MuseTalk autoalojado.....	19
8. Conclusiones.....	20
9. Fuentes consultadas.....	20

1. Introducción y contexto

La plataforma Virtual Patient permite a estudiantes de medicina practicar entrevistas clínicas con un paciente simulado impulsado por un agente conversacional (LangGraph + FastAPI, con Azure OpenAI como proveedor de LLM, TTS y embeddings). Actualmente la "cara" del paciente es una imagen estática y la voz se reproduce mediante un elemento <audio> a partir de texto sintetizado por Azure OpenAI TTS, sin video con sincronización labial ni transporte en tiempo real (WebRTC o WebSocket).

El documento de arquitectura provisto identifica dos patrones de integración de un avatar conversacional: la Opción A, en la que el backend orquesta la llamada al proveedor de avatar (patrón servidor-a-servidor, manteniendo las llaves de API del lado del servidor y reutilizando la canalización de grabación existente), y la Opción B, en la que el navegador abre directamente una sesión WebRTC con el proveedor. Este informe evalúa alternativas de mercado y de código abierto bajo ese marco, con el fin de recomendar la tecnología a integrar.

El presente informe responde a cinco preguntas: (1) qué metodología y criterios de inclusión/exclusión se usaron para acotar el universo de herramientas; (2) cómo se comparan las alternativas mediante una matriz de criterios ponderada; (3) qué resultados arrojan las pruebas exploratorias de latencia y costo estimado por entrevista; (4) qué tan viable es un escenario sin presupuesto para APIs de pago; y (5) cuál es la recomendación final, junto con una alternativa abierta de respaldo.

2. Metodología de búsqueda y criterios de inclusión/exclusión

2.1 Estrategia de búsqueda

La identificación de alternativas combinó cuatro fuentes: (i) documentación oficial de cada proveedor (páginas de precios, documentación técnica y de arquitectura); (ii) análisis comparativos independientes de terceros publicados durante 2026, incluyendo una revisión especializada del panorama de "avatares en vivo" que evalúa diez proveedores bajo criterios homogéneos de transporte, API y latencia percibida; (iii) repositorios de código abierto en GitHub para modelos de sincronización labial y plataformas de humanos digitales autoalojadas; y (iv) foros técnicos (Microsoft Q&A, comunidades de desarrolladores) para contrastar cifras de precio publicadas frente a la experiencia real reportada por integradores.

La búsqueda no se limitó a las tres opciones inicialmente contempladas (Tavus, Azure AI Speech Avatar y ElevenLabs), sino que se amplió deliberadamente para cubrir tanto plataformas comerciales adicionales (HeyGen, D-ID, Simli, Anam, entre otras) como alternativas de código abierto autoalojables (MuseTalk, Wav2Lip, SadTalker y plataformas de humano digital construidas sobre ellas).

2.2 Criterios de inclusión

- Debe aceptar texto o audio como entrada y producir video con sincronización labial (no basta con generar solo imagen estática o solo audio).
- Debe soportar, de forma nativa o mediante una integración documentada, un modo de conversación en tiempo real (streaming, no solo generación de video por lotes).
- Debe exponer una API o SDK integrable desde un backend Python/FastAPI o desde un cliente web, compatible con al menos uno de los dos patrones (A o B) descritos en la arquitectura actual.
- Debe tener documentación pública suficiente (precios, límites, latencia declarada o medible) para permitir una comparación informada.
- Para las alternativas de código abierto: debe contar con una licencia permisiva para uso educativo/institucional (MIT, Apache 2.0 o equivalente) y evidencia de funcionamiento en tiempo real (≥ 15 -20 fps) en hardware GPU razonable.

2.3 Criterios de exclusión

- Herramientas orientadas exclusivamente a generación de video por lotes sin modo conversacional en tiempo real (p. ej. la función "Avatars" de ElevenCreative por sí sola, o Synthesia, cuya oferta "Live" no estaba disponible públicamente al momento de esta revisión).
- Plataformas que solo ofrecen un editor "sin código" cerrado, sin API programable, incompatibles con la orquestación ya existente en VirtualPatientController/SpeechService.
- Productos anunciados pero no disponibles en general (GA) para integración por API al momento de la búsqueda.
- Alternativas de código abierto sin capacidad demostrada de operar en tiempo real (modelos de generación por lotes que tardan varios minutos por segundo de video quedan fuera del alcance de una interfaz conversacional).
- Proveedores cuya oferta de avatar en tiempo real fue señalada como descontinuada por integradores externos al momento de la búsqueda (p. ej. referencias a Hedra como "ahora descontinuada" en catálogos de integración de terceros); se documentan como referencia histórica pero no se evalúan en la matriz.

2.4 Universo de herramientas identificadas

La siguiente tabla resume el universo de alternativas identificadas y su disposición final (evaluada en la matriz de la sección 3, o excluida/mencionada solo como referencia).

Herramienta	Categoría	Disposición	Motivo
Tavus (CVI)	Comercial	Evaluada	Una de las tres opciones originales; cumple todos los criterios.
Azure AI Speech Avatar / Voice Live	Comercial	Evaluada	Opción original; mismo proveedor que el LLM/TTS actual.
ElevenLabs (+ HeyGen LiveAvatar)	Comercial	Evaluada	Sin video nativo en tiempo real; se evalúa vía integración oficial con LiveAvatar.
HeyGen (Streaming/Interactive Avatar)	Comercial	Cubierta en la fila anterior	Es el motor de video de la integración ElevenLabs + LiveAvatar.
D-ID Agents	Comercial	Evaluada	Mencionada en el documento de arquitectura provisto.
Simli	Comercial	Evaluada	API audio-to-video de bajo costo hallada en la búsqueda ampliada.
Anam (CARA-4)	Comercial	Evaluada	Menor latencia declarada entre proveedores comerciales.
MuseTalk + Wav2Lip (autoalojado)	Código abierto	Evaluada	Única combinación open source con tiempo real (≥ 30 fps) y licencia permisiva.
BeyondPresence, bitHuman,	Comercial	Referenciadas, no evaluadas	Cumplen inclusión; se

Herramienta	Categoría	Disposición	Motivo
Lemon Slice, Uneeq			priorizaron 7 alternativas para una matriz manejable.
Synthesia "Live"	Comercial	Excluida	No disponible públicamente por API (anunciada, no GA).
Hedra	Comercial	Excluida	Reportada como descontinuada en catálogos de integración de terceros.
SadTalker	Código abierto	Excluida, referenciada	Genera desde una foto pero no está optimizado para tiempo real.

3. Matriz de criterios ponderada

3.1 Definición de criterios y ponderación

Los pesos se definieron a partir de las prioridades explícitas del proyecto: (a) el costo es la restricción más mencionada dado que la herramienta debe operar a escala de curso; (b) la latencia es crítica porque una entrevista clínica simulada exige turnos de conversación fluidos; (c) la compatibilidad con la arquitectura reduce el riesgo y el tiempo de integración; y (d) la preservación del control de voz/personalidad, la privacidad de datos educativos de salud y el soporte de español son requisitos funcionales del dominio. La disponibilidad de una opción autoalojada se pondera de forma más baja porque es, en sí misma, el objeto del análisis de viabilidad de la sección 5, no un requisito de la integración principal.

Criterio	Peso	Peso (%)
Costo por minuto / entrevista	20	20%
Latencia conversacional	20	20%
Compatibilidad con la arquitectura actual	15	15%
Control de voz y personalidad (vocal_style_policy)	10	10%
Privacidad y cumplimiento normativo	10	10%
Soporte de idioma español	10	10%
Madurez del proveedor / riesgo de continuidad	10	10%
Disponibilidad de opción autoalojada	5	5%

Escala de puntuación por criterio: 1 = deficiente / no cumple, 3 = aceptable con reservas, 5 = excelente / cumple plenamente. El puntaje ponderado de cada criterio es $\text{puntaje} \times \text{peso} / 100$; el puntaje ponderado total de cada alternativa es la suma de sus ocho puntajes ponderados, sobre una escala máxima de 5.00.

3.2 Evaluación individual de cada alternativa

1. Tavus (Conversational Video Interface — CVI)

Criterio (peso)	Punt.	Justificación
Costo por minuto / entrevista (20%)	2.5	≈USD 59/mes por 100 min; sobreconsumo USD 0.32–0.37/min. Medio-alto para volumen de curso.

Criterio (peso)	Punt.	Justificación
Latencia conversacional (20%)	4.0	≈600 ms extremo a extremo (dato del proveedor); percepción de terceros: "media".
Compatibilidad con la arquitectura actual (15%)	4.0	Nueva cuenta de proveedor, pero SDK maduro (React/iframe/JS) y soporte LiveKit/Pipecat; encaja con patrón A.
Control de voz y personalidad (vocal_style_policy) (10%)	3.0	Voz propia (Phoenix/Sparrow); control fino de prosodia limitado si no se sustituye el TTS de Tavus.
Privacidad y cumplimiento normativo (10%)	4.0	SOC2/HIPAA solo en plan Enterprise; no incluido en planes de entrada.
Soporte de idioma español (10%)	4.0	Más de 30 idiomas, incluido español.
Madurez del proveedor / riesgo de continuidad (10%)	4.0	Empresa YC con inversión activa y adopción amplia en salud y formación.
Disponibilidad de opción autoalojada (5%)	1.0	No ofrece variante autoalojada ni de código abierto.
Puntaje ponderado total	3.45 / 5.00	

2. Azure AI Speech Avatar / Voice Live (Microsoft)

Criterio (peso)	Punt.	Justificación
Costo por minuto / entrevista (20%)	2.5	≈EUR 0.52/min (≈USD 0.56/min), facturado por segundo activo. Entre los más caros del grupo.
Latencia conversacional (20%)	4.0	Red de borde de Microsoft orientada a baja latencia; sin cifra pública única.
Compatibilidad con la arquitectura actual (15%)	5.0	Mismo proveedor y cuenta que Azure OpenAI (LLM/TTS ya usados); ruta de menor fricción.
Control de voz y personalidad (vocal_style_policy) (10%)	5.0	Reutiliza voces neuronales y vocal_style_policy.py sin cambios; preserva prosodia por personalidad.
Privacidad y cumplimiento normativo (10%)	5.0	HIPAA elegible (BAA), SOC2, ISO 27001; adecuado para datos clínicos educativos.
Soporte de idioma español (10%)	5.0	>140 locales, >600 voces; muy buenas variantes de español latinoamericano.
Madurez del proveedor / riesgo de continuidad (10%)	4.0	Respaldo Microsoft; función de avatar relativamente nueva, en expansión regional.
Disponibilidad de opción autoalojada (5%)	1.0	Sin variante autoalojada; servicio cerrado.
Puntaje ponderado total	4.00 / 5.00	

3. ElevenLabs (voz) + HeyGen LiveAvatar (video, vía integración ElevenAgents)

Criterio (peso)	Punt.	Justificación
Costo por minuto / entrevista (20%)	3.0	HeyGen ≈USD 0.10–0.20/min + costo de TTS de ElevenLabs por carácter. Costo moderado.
Latencia conversacional (20%)	3.0	Hereda la latencia de HeyGen LiveAvatar: "media" según evaluación independiente.
Compatibilidad con la arquitectura actual (15%)	2.5	ElevenLabs no genera video en tiempo real nativo; requiere su integración oficial con HeyGen LiveAvatar (dos proveedores en cadena).
Control de voz y personalidad (vocal_style_policy) (10%)	4.5	ElevenLabs sobresale en clonación/expresividad de voz; réplica fiel de la política vocal si sustituye el TTS de Azure.
Privacidad y cumplimiento normativo (10%)	3.0	Cumplimiento variable; ElevenLabs con niveles empresariales, HeyGen menos explícito para el nivel en tiempo real.
Soporte de idioma español (10%)	4.5	ElevenLabs: 30+ idiomas de alta calidad; HeyGen: 175+ idiomas en su capa de voz/traducción.
Madurez del proveedor / riesgo de continuidad (10%)	4.5	Ambos proveedores con adopción y financiamiento sólidos (ARR de cientos de millones USD).
Disponibilidad de opción autoalojada (5%)	1.0	Ninguno ofrece opción autoalojada.
Puntaje ponderado total	3.27 / 5.00	

4. D-ID Agents

Criterio (peso)	Punt.	Justificación
Costo por minuto / entrevista (20%)	2.0	Créditos (0.5 cada 30 s); equivalente ≈USD 0.32–0.35/min, entre los más altos evaluados.
Latencia conversacional (20%)	2.0	Evaluaciones independientes la describen como "lenta" frente a pares de su categoría.
Compatibilidad con la arquitectura actual (15%)	2.5	WebRTC vía Janus sin SDK de alto nivel ni LiveKit/Pipecat; más esfuerzo de integración manual.
Control de voz y personalidad (vocal_style_policy) (10%)	2.5	Acepta audio de terceros en algunos flujos; documentación pública limitada sobre sustitución completa del TTS.
Privacidad y cumplimiento normativo (10%)	3.0	Planes Enterprise con seguridad avanzada, pero menos detalle público de certificaciones que Azure/Tavus.

Criterio (peso)	Punt.	Justificación
Soporte de idioma español (10%)	3.5	Soporte multilingüe amplio declarado por el proveedor.
Madurez del proveedor / riesgo de continuidad (10%)	3.5	Establecida desde 2017; reportes de discrepancias de precio y quejas de soporte.
Disponibilidad de opción autoalojada (5%)	1.0	No ofrece variante autoalojada.
Puntaje ponderado total	2.48 / 5.00	

5. Simli (Audio-to-Video API)

Criterio (peso)	Punt.	Justificación
Costo por minuto / entrevista (20%)	5.0	USD 0.009/min, la más baja del grupo por amplio margen; USD 10 gratis + 50 min/mes recurrentes.
Latencia conversacional (20%)	4.0	Evaluación independiente: latencia "buena"; el proveedor la posiciona como su diferenciador principal.
Compatibilidad con la arquitectura actual (15%)	4.5	API "audio-to-video": recibe el audio ya generado por el TTS existente; encaja con el patrón A sin reemplazar el pipeline de voz.
Control de voz y personalidad (vocal_style_policy) (10%)	5.0	Al recibir audio pregenerado, conserva íntegramente vocal_style_policy.py: Simli nunca sustituye la voz.
Privacidad y cumplimiento normativo (10%)	2.5	Empresa joven (2023, YC); sin certificaciones HIPAA/SOC2 públicas identificadas para este nivel.
Soporte de idioma español (10%)	4.0	Agnóstica de idioma (la voz viene del TTS externo); hereda el español ya validado en Azure TTS.
Madurez del proveedor / riesgo de continuidad (10%)	2.5	Soporte vía Discord; menor huella empresarial que Tavus/HeyGen, mayor riesgo de continuidad.
Disponibilidad de opción autoalojada (5%)	1.5	No es código abierto, pero "trae tu propio audio" reduce el bloqueo de proveedor.
Puntaje ponderado total	3.95 / 5.00	

6. Anam (CARA-4)

Criterio (peso)	Punt.	Justificación
Costo por minuto / entrevista (20%)	3.0	USD 0.18/min; costo intermedio, sin nivel gratuito recurrente bien documentado.

Criterio (peso)	Punt.	Justificación
Latencia conversacional (20%)	4.5	180 ms declarados con CARA-4, la cifra más baja entre proveedores comerciales evaluados.
Compatibilidad con la arquitectura actual (15%)	3.0	API tipo "agente" (voz+video integrados); integración con LiveKit requiere solución alterna.
Control de voz y personalidad (vocal_style_policy) (10%)	2.5	Modelo de agente integrado: control de prosodia limitado frente a un flujo audio-to-vídeo.
Privacidad y cumplimiento normativo (10%)	2.5	Empresa joven (spin-out de Synthesia, 2023); certificaciones no ampliamente publicadas.
Soporte de idioma español (10%)	4.5	Declara 70+ idiomas con voces nativas, ~95% del mercado mundial según el proveedor.
Madurez del proveedor / riesgo de continuidad (10%)	3.5	Buen respaldo de financiamiento; trayectoria corta ("#1 en Avatar Benchmark 2026" según el propio proveedor).
Disponibilidad de opción autoalojada (5%)	1.0	No ofrece variante autoalojada.
Puntaje ponderado total	3.30 / 5.00	

7. Pila de código abierto autoalojada (MuseTalk + Wav2Lip como respaldo)

Criterio (peso)	Punt.	Justificación
Costo por minuto / entrevista (20%)	4.5	Sin licencia (MuseTalk es MIT); solo costo de cómputo GPU, ≈USD 0.13–0.26 por entrevista de 15 min (sección 5.3). No incluye el desarrollo inicial.
Latencia conversacional (20%)	3.0	≥30 fps en GPU V100/A100; proyectos de referencia reportan 2–4 s hasta el primer fragmento en pipelines completos.
Compatibilidad con la arquitectura actual (15%)	3.0	Se integra en el patrón A (backend ya orquesta LLM/TTS), pero exige construir señalización WebRTC y el servicio de renderizado, hoy inexistentes.
Control de voz y personalidad (vocal_style_policy) (10%)	5.0	Recibe directamente el audio del TTS de Azure: preserva por completo la política vocal actual, sin intermediarios.
Privacidad y cumplimiento normativo (10%)	5.0	Corre íntegramente en infraestructura propia: mejor perfil de privacidad, ningún dato sale a un tercero.
Soporte de idioma español (10%)	5.0	Agnóstica de idioma (voz del TTS existente); hereda el español ya

Criterio (peso)	Punt.	Justificación
		validado en el sistema.
Madurez del proveedor / riesgo de continuidad (10%)	3.0	Comunidad activa en GitHub (Tencent); sin soporte comercial ni SLA, exige capacidad de DevOps/ML propia.
Disponibilidad de opción autoalojada (5%)	5.0	Es, por definición, la alternativa autoalojada y de código abierto evaluada.
Puntaje ponderado total	4.00 / 5.00	

3.3 Resultado y ranking

Puesto	Alternativa	Puntaje ponderado
1	2. Azure AI Speech Avatar / Voice Live (Microsoft)	4.00 / 5.00
2	7. Pila de código abierto autoalojada (MuseTalk + Wav2Lip como respaldo)	4.00 / 5.00
3	5. Simli (Audio-to-Video API)	3.95 / 5.00
4	1. Tavus (Conversational Video Interface — CVI)	3.45 / 5.00
5	6. Anam (CARA-4)	3.30 / 5.00
6	3. ElevenLabs (voz) + HeyGen LiveAvatar (video, vía integración ElevenAgents)	3.27 / 5.00
7	4. D-ID Agents	2.48 / 5.00

Azure AI Speech Avatar / Voice Live y la pila autoalojada MuseTalk quedan empatadas en el primer lugar (4.00/5.00), seguidas muy de cerca por Simli (3.95/5.00). Los tres comparten una misma razón de fondo: al operar sobre el audio ya generado por el TTS existente (o compartir directamente ese proveedor, en el caso de Azure), preservan la política de estilo vocal actual y encajan de forma natural en el patrón A de la arquitectura. Se diferencian en el eje que decide la recomendación de la sección 6: Azure gana en madurez, cumplimiento normativo y riesgo de continuidad del proveedor; MuseTalk gana en privacidad total de datos y costo marginal, pero exige construir desde cero la capa de tiempo real; y Simli ofrece el mejor costo comercial puro, al precio de ser la empresa con menor huella de cumplimiento del grupo. Esta cercanía entre los tres primeros lugares es la base de la recomendación por fases de la sección 6, que no elige un único ganador sino que combina las tres alternativas según el horizonte de tiempo y el presupuesto disponible.

4. Resultados de las pruebas exploratorias

4.1 Nota metodológica y alcance

Es importante precisar el alcance de esta sección: los datos de latencia y costo presentados a continuación se construyeron a partir de documentación pública de cada proveedor, benchmarks independientes publicados por integradores externos y calculadoras de precios de terceros, contrastados entre sí — no a partir de mediciones directas ejecutadas por quien redacta este informe contra cuentas activas de Tavus, Azure, ElevenLabs/HeyGen, D-ID, Simli o Anam, dado que dicho ejercicio requiere credenciales de pago, cuentas verificadas y acceso de red a los endpoints de cada proveedor. Esta es una fase de "escritorio" (desk research)

previa a un piloto técnico. Antes de comprometer presupuesto, se recomienda ejecutar el protocolo de validación de la sección 4.4 con cuentas de prueba reales sobre los 2-3 finalistas.

4.2 Latencia reportada por proveedor

Proveedor	Latencia reportada	Fuente / naturaleza del dato
Tavus	≈ 600 ms extremo a extremo (cifra del propio proveedor); percepción cualitativa de terceros: "media"	Blog oficial de Tavus y comparativo independiente de costo de video conversacional
Azure AI Speech Avatar / Voice Live	Sin cifra única publicada; el proveedor lo describe como optimizado para "baja latencia" sobre su red de borde	Documentación de Microsoft Learn sobre síntesis en tiempo real y Voice Live
ElevenLabs + HeyGen LiveAvatar	Hereda la latencia de HeyGen LiveAvatar: percepción cualitativa "media"	Análisis independiente de 10 proveedores de avatares en vivo (ene. 2026)
D-ID Agents	Percepción cualitativa: "lenta" frente a pares de la misma categoría	Análisis independiente de 10 proveedores de avatares en vivo (ene. 2026)
Simli	Percepción cualitativa: "buena"; el proveedor declara la latencia como su diferenciador principal	Análisis independiente de 10 proveedores; material de producto de Simli/Verda
Anam (CARA-4)	180 ms (cifra declarada por el proveedor)	Sitio oficial de Anam
MuseTalk (autoalojado)	Renderizado ≥30 fps en GPU V100/A100; pipelines completos de referencia reportan 2-4 s hasta el primer fragmento de video (incluye STT+LLM+TTS+lip-sync), y variantes similares reportan latencia inicial tan baja como 3 s	Documentación técnica de MuseTalk (TMElyralab) y repositorios de referencia en GitHub

Nota: las cifras en milisegundos declaradas por los proveedores (Tavus, Anam) no son directamente comparables entre sí sin conocer el método de medición de cada uno (p. ej. si incluyen o no el tiempo de LLM). Las calificaciones cualitativas ("buena", "media", "lenta") provienen de una única fuente comparativa de terceros y deben tratarse como orientativas, no concluyentes, hasta la validación empírica.

4.3 Modelo de costo estimado por entrevista

Supuestos del modelo: duración promedio de una entrevista clínica simulada = 15 minutos (equivalente a un encuentro tipo OSCE breve); volumen de referencia = 200 entrevistas/mes (un curso de tamaño medio en uso formativo regular). Los precios son tarifas públicas de lista vigentes en agosto de 2026 y no incluyen descuentos por volumen ni negociación empresarial, que suelen estar disponibles a partir de cierto consumo.

Alternativa	Tarifa publicada	Costo / entrevista (15 min)	Costo mensual estimado (200 entrevistas)
Tavus	≈ USD 0.35/min (sobreconsumo) + base de USD 59/mes (100 min incl.)	≈ USD 5.37 (incl. prorrateo de base)	≈ USD 1,074
Azure AI Speech Avatar / Voice Live	≈ USD 0.56/min (EUR 0.521)	≈ USD 8.44	≈ USD 1,688

Alternativa	Tarifa publicada	Costo / entrevista (15 min)	Costo mensual estimado (200 entrevistas)
ElevenLabs + HeyGen LiveAvatar	≈ USD 0.15/min (video) + TTS por caracteres	≈ USD 2.25 – 2.75	≈ USD 450 – 550
D-ID Agents	≈ USD 0.32 – 0.35/min equivalente	≈ USD 5.25	≈ USD 1,050
Simli	USD 0.009/min	≈ USD 0.14	≈ USD 27
Anam (CARA-4)	USD 0.18/min	≈ USD 2.70	≈ USD 540
MuseTalk autoalojado	Solo cómputo GPU (USD 0.34–0.69/h, facturado por segundo)	≈ USD 0.13 – 0.26 (cómputo puro)	≈ USD 25 – 50 (cómputo puro; excluye ingeniería inicial)

La dispersión de costo es amplia: entre USD 0.14 y USD 8.44 por entrevista según la alternativa, más de 60 veces de diferencia entre el extremo más económico (Simli) y el más costoso (Azure Avatar) a esta duración. Esto confirma que el costo no puede evaluarse de forma aislada del resto de criterios: Azure obtiene el mejor puntaje ponderado global pese a ser la opción más cara por minuto, porque compensa ese costo con compatibilidad, privacidad y control de voz; mientras que Simli combina bajo costo con una compatibilidad casi tan alta como la de Azure, precisamente por operar sobre el audio ya generado por el TTS existente.

4.4 Protocolo de validación empírica recomendado

Antes de comprometer presupuesto o esfuerzo de ingeniería significativo, se recomienda ejecutar el siguiente protocolo con los 2-3 finalistas (sugerido: Azure AI Speech Avatar, Simli y una prueba de concepto de MuseTalk):

1. Crear cuentas de prueba/nivel gratuito para cada finalista y registrar la latencia real medida (no declarada) mediante estadísticas WebRTC (getStats()) en el navegador) para al menos 30 turnos de conversación simulada.
2. Medir el tiempo hasta el primer fotograma de video ("time to first frame") desde que el backend recibe el texto de respuesta del LLM.
3. Grabar 10 minutos de conversación con cada finalista y evaluar de forma ciega, con un grupo pequeño de estudiantes o docentes, la naturalidad percibida y la sincronización labial.
4. Verificar en la práctica que el flujo de grabación de 4 pistas (audio/video de estudiante, audio de paciente, UI del paciente renderizada) sigue siendo capturable mediante MediaRecorder sobre el elemento <video> resultante.
5. Confirmar con cada proveedor, por escrito, sus condiciones de tratamiento de datos si se llegan a usar transcripciones de entrevistas clínicas simuladas con información potencialmente sensible.
6. Registrar el costo real facturado tras el piloto y compararlo contra las estimaciones de la sección 4.3 para calibrar el modelo antes de la decisión final.

5. Análisis de viabilidad — escenario sin presupuesto para APIs de pago

5.1 Niveles gratuitos disponibles

Proveedor	Nivel gratuito	Suficiente para uso de curso!=uso de demo
Tavus	20-25 min/mes en el plan gratuito (PALs/CVI)	Solo demo/POC

Proveedor	Nivel gratuito	Suficiente para uso de curso!=uso de demo
Simli	USD 10 de crédito al registrarse + 50 min/mes recurrentes	Solo demo/POC
D-ID	Prueba de 14 días con minutos limitados (≈5-20 min) y marca de agua	Solo demo/POC
Anam	Nivel gratuito de exploración con minutos limitados según el plan (detalle exacto no publicado en su totalidad; verificar directamente)	Solo demo/POC
HeyGen	Sin nivel gratuito de API desde febrero de 2026 (solo pago por uso desde USD 5)	No aplica
ElevenLabs (TTS)	Nivel gratuito de caracteres/mes para texto a voz; el video en tiempo real (LiveAvatar) no tiene nivel gratuito propio	No aplica para el componente de video
Azure (avatar)	Sin nivel gratuito recurrente para el avatar en tiempo real; existe el programa Azure for Students (crédito único, aprox. USD 100) y posibles convenios académicos institucionales	Solo piloto acotado, no recurrente

En conjunto, ningún nivel gratuito comercial cubre un uso realista de curso (cientos de minutos por mes de forma sostenida): todos están pensados como incentivos de evaluación de producto, no como capa de producción. El único camino verdaderamente sostenible sin presupuesto recurrente es la autoalojada.

5.2 Alternativa de código abierto autoalojada

La combinación recomendada para un escenario sin presupuesto es: Whisper (transcripción, ya de código abierto) → LLM (puede seguir siendo Azure OpenAI si ya existe crédito docente/institucional, o un modelo local vía Ollama/vLLM) → TTS (puede reutilizarse Azure OpenAI TTS si hay crédito disponible, o sustituirse por una alternativa abierta como Coqui XTTS o Piper) → MuseTalk para la sincronización labial en tiempo real, con Wav2Lip como motor alternativo más liviano si el hardware disponible no alcanza para MuseTalk. Todo el pipeline es MIT/Apache y puede ejecutarse íntegramente dentro de infraestructura propia, sin enviar audio, video ni transcripciones a un tercero.

Existen ya repositorios de referencia en GitHub que implementan exactamente este patrón extremo a extremo (micrófono → Whisper → LLM → TTS con clonación de voz → MuseTalk → video), lo cual reduce el riesgo de tener que construir la orquestación completa desde cero.

5.3 Estimación de costo de cómputo para autoalojamiento

GPU	Tarifa por hora (nube económica)	Costo por entrevista de 15 min	Costo de 200 entrevistas/mes
RTX A5000 (24 GB)	≈ USD 0.27/h	≈ USD 0.07	≈ USD 13
RTX 4090 (24 GB)	≈ USD 0.34 - 0.69/h	≈ USD 0.09 - 0.17	≈ USD 17 - 35
A100 PCIe (80 GB)	≈ USD 1.39/h	≈ USD 0.35	≈ USD 70
GPU gratuita (Google Colab, T4)	USD 0 (con límites de sesión y disponibilidad no)	USD 0	No apto para producción; solo prototipado

GPU	Tarifa por hora (nube económica)	Costo por entrevista de 15 min	Costo de 200 entrevistas/mes
	garantizada)		

Al facturarse por segundo, el costo de cómputo solo se causa mientras la GPU está efectivamente en uso; una GPU económica (RTX A5000/4090) alquilada únicamente durante las ventanas de evaluación programadas del curso mantiene el costo de cómputo puro en el orden de USD 15-35 mensuales para el volumen de referencia — muy por debajo de cualquier alternativa comercial evaluada, aunque sin contar el tiempo de ingeniería inicial de construir y mantener el servicio.

5.4 Oportunidades del contexto académico

Al tratarse de un proyecto vinculado a la Universidad de los Andes, vale la pena verificar dos rutas adicionales antes de asumir un costo de nube: (i) créditos académicos de Azure para estudiantes/instituciones (Azure for Students u otros convenios de la universidad con Microsoft), que podrían cubrir un piloto acotado del avatar de Azure sin costo directo; y (ii) disponibilidad de cómputo GPU de investigación dentro de la universidad (por ejemplo, a través de laboratorios como FLAG Lab u otros grupos con clústeres propios), que eliminaría por completo el costo de alquiler de GPU para la ruta autoalojada. Ambas rutas deben confirmarse directamente con la unidad de TI o el grupo de investigación correspondiente, ya que su disponibilidad no depende de este análisis.

5.5 Conclusión de viabilidad

Sin presupuesto para APIs de pago, es viable construir y demostrar un prototipo funcional del avatar conversacional, pero por dos rutas distintas según el objetivo: para una demostración puntual (sustentación, video para una convocatoria de financiación, prueba de concepto ante el equipo), los niveles gratuitos de Simli o Tavus son suficientes y requieren cero desarrollo adicional de infraestructura. Para un uso sostenido a escala de curso, la única ruta viable sin presupuesto recurrente es la pila autoalojada basada en MuseTalk, apoyada preferiblemente en cómputo académico institucional o, en su defecto, en GPU de nube económica alquilada solo durante ventanas de uso, lo que mantiene el costo marginal en la práctica cercano a cero frente a cualquier alternativa comercial.

6. Recomendación argumentada

6.1 Recomendación principal: Azure AI Speech Avatar / Voice Live

Se recomienda integrar Azure AI Speech Avatar (u, óptimamente, Voice Live si se busca simplificar aún más la orquestación de LLM+TTS+avatar en una sola llamada) como la tecnología principal, siguiendo el patrón A (servidor-a-servidor) ya descrito en el documento de arquitectura provisto. Las razones son cuatro: (1) obtiene el puntaje más alto en la matriz ponderada; (2) es el único proveedor evaluado que comparte cuenta y facturación con el LLM y el TTS ya integrados, lo que el propio documento de arquitectura señala como la ruta "más sencilla"; (3) permite conservar sin modificaciones la política de estilo vocal por personalidad (vocal_style_policy.py), un activo funcional ya construido; y (4) ofrece el perfil de cumplimiento normativo más sólido para un producto que procesa datos de práctica clínica de estudiantes de medicina. Su principal desventaja es el costo por minuto, el más alto del conjunto evaluado, por lo que se recomienda iniciar con un piloto acotado (no todo el curso desde el primer despliegue) y activar la optimización "Use Local Video for Idle" documentada por Microsoft para reducir el gasto en los tramos sin habla activa.

6.2 Alternativa comercial secundaria: Simli

Antes de comprometer el presupuesto de Azure a gran escala, se recomienda un spike técnico de dos semanas evaluando Simli en paralelo. Al exponer una API "audio-to-video" que recibe el audio ya generado por el TTS existente, Simli permite conservar exactamente la misma política de voz que Azure, con una fracción del costo ($\approx$ USD 0.14 frente a $\approx$ USD 8.44 por entrevista de 15 minutos en las tarifas públicas actuales). Su desventaja frente a Azure es una empresa más joven, con menor huella de cumplimiento normativo documentada y mayor riesgo de continuidad a mediano plazo — factores que pesan más en un producto que eventualmente manejará datos de estudiantes de medicina de forma sostenida.

6.3 Alternativa abierta de respaldo: MuseTalk autoalojado

Independientemente de cuál proveedor comercial se elija inicialmente, se recomienda desarrollar en paralelo (no como plan de contingencia tardío, sino como línea de trabajo activa desde ahora) una prueba de concepto de la pila autoalojada MuseTalk + Wav2Lip descrita en la sección 5.2. Esta alternativa cumple un doble propósito: sirve como respaldo ante el escenario sin presupuesto (sección 5), y actúa como cobertura estratégica a largo plazo frente al riesgo de que cualquier proveedor comercial suba precios, cambie condiciones o discontinúe el servicio — algo que ya ha ocurrido en este mismo mercado (ver la exclusión de Hedra en la sección 2.4). Al operar sobre audio pregenerado, es la única alternativa evaluada que no depende de negociar con un tercero el uso de datos clínicos simulados.

6.4 Hoja de ruta sugerida

1. Fase 1 (2 semanas): spikes técnicos en paralelo con los niveles gratuitos de Azure AI Speech Avatar y de Simli, siguiendo el protocolo de validación de la sección 4.4.
2. Fase 1B (en paralelo): prueba de concepto mínima de MuseTalk sobre una GPU alquilada por horas o sobre Google Colab, para validar la latencia real del pipeline completo en el contexto de este proyecto.
3. Fase 2 (punto de decisión): comparar los resultados medidos de la Fase 1 contra las estimaciones de este informe y confirmar la elección entre Azure, Simli o una combinación de ambos (p. ej. Azure para el despliegue institucional formal, Simli para entornos de práctica de bajo costo).
4. Fase 3: integración de producción en SpeechService siguiendo el patrón A, reutilizando la canalización de grabación de 4 pistas ya existente, con el elemento <video> reemplazando la imagen estática del avatar.


5. Fase 4 (continua): mantener la pila MuseTalk como opción de respaldo documentada y probada, revisitándola si el costo mensual real supera de forma sostenida las proyecciones de la sección 4.3.

7. Adaptación arquitectónica para las alternativas finalistas

Esta sección traduce la recomendación de la sección 6 en cambios concretos sobre el sistema descrito en el documento de arquitectura provisto (VirtualPatientController, LangGraph Workflow, VirtualPatientAgent, SpeechService, Media storage y ChatInterface.tsx). Para cada uno de los tres finalistas se muestra un diagrama de adaptación y una tabla de componente por componente, usando el mismo código de color: gris azulado = sin cambios, azul oscuro = componente existente que se modifica, y naranja = componente completamente nuevo. Los tres siguen el patrón A (servidor-a-servidor) del documento original: el backend sigue orquestando la sesión del avatar y las llaves de API permanecen del lado del servidor.

7.1 Azure AI Speech Avatar / Voice Live

Adaptación de arquitectura — Azure AI Speech Avatar / Voice Live




Componente	Estado	Cambio requerido
ChatInterface.tsx (frontend)	MODIFICADO	Sustituir el elemento <audio> por un <video> suscrito al stream WebRTC del avatar; el resto del componente de conversación no cambia.
SpeechService	MODIFICADO	Extender (o migrar a Voice Live) la llamada actual de TTS por la síntesis de avatar en tiempo real del Speech SDK; vocal_style_policy.py se reutiliza sin modificaciones porque Azure sigue siendo el mismo proveedor de voz.

Componente	Estado	Cambio requerido
Router /medical-interviews/{id}/messages	SIN CAMBIOS	El contrato de texto (POST con content, respuesta con messages[]) no cambia; se agrega un endpoint complementario para negociar la sesión WebRTC (oferta/respuesta SDP).
Nuevo endpoint de señalización WebRTC	NUEVO	Pequeño endpoint en FastAPI que intercambia la oferta/respuesta SDP entre el navegador y el servicio de avatar de Azure; no maneja audio/video, solo negociación.
VirtualPatientController / Workflow / Agent	SIN CAMBIOS	La orquestación del LLM y la memoria vectorial permanecen idénticas; solo cambia lo que ocurre después de generarse el texto de respuesta.
Media storage y grabación de 4 pistas	SIN CAMBIOS	MediaRecorder sigue capturando el mismo número de pistas; ahora captura el <video> del avatar en lugar de la imagen estática renderizada.
Tabla de mensajes en PostgreSQL	MODIFICADO (opcional)	Se puede añadir un campo avatar_session_id para trazabilidad y depuración, sin alterar el esquema de mensajes existente.

Es la integración de menor huella de cambio: no se introduce un proveedor nuevo, y el único componente genuinamente nuevo es el endpoint de negociación WebRTC.

7.2 Simli (Audio-to-Video API)

Adaptación de arquitectura — Simli (Audio-to-Video API)




Componente	Estado	Cambio requerido
ChatInterface.tsx (frontend)	MODIFICADO	Mismo cambio que en Azure: <audio> se reemplaza por <video> suscrito al stream WebRTC (infraestructura Daily usada por Simli).
SpeechService	SIN CAMBIOS	Sigue generando el audio con Azure OpenAI TTS exactamente como hoy; Simli nunca sustituye la voz, por lo que vocal_style_policy.py no se toca.
AvatarRenderService (wrapper de Simli)	NUEVO	Módulo nuevo, invocado justo después de que SpeechService genera el audio: lo envía a la API audio-to-video de Simli y recibe la referencia del stream de video sincronizado.
Nuevo endpoint de señalización WebRTC	NUEVO	Análogo al de Azure, pero negociando contra la infraestructura de Simli en lugar de Azure Speech.
VirtualPatientController / Workflow / Agent	SIN CAMBIOS	Ningún cambio: Simli entra únicamente en el tramo posterior a la generación de audio.
Media storage y grabación de 4 pistas	SIN CAMBIOS	Igual que en Azure: se captura el nuevo <video> con el mismo mecanismo

Componente	Estado	Cambio requerido
		MediaRecorder ya existente.

Requiere un componente nuevo (AvatarRenderService) que Azure no necesita, pero a cambio dos de los cambios de Azure desaparecen: SpeechService no se toca en absoluto, y no hay que migrar de proveedor de voz ni de facturación.

7.3 MuseTalk autoalojado

Adaptación de arquitectura — MuseTalk autoalojado



Componente	Estado	Cambio requerido
ChatInterface.tsx (frontend)	MODIFICADO	Mismo cambio de <audio> a <video>, ahora suscrito al servidor de señalización WebRTC propio en lugar de uno de un proveedor externo.
SpeechService	SIN CAMBIOS	Igual que con Simli: sigue generando el audio con Azure OpenAI TTS sin ninguna modificación.
AvatarRenderService interno	NUEVO	Servicio propio que recibe el audio generado y orquesta la solicitud de sincronización labial hacia el worker GPU.
Worker GPU MuseTalk	NUEVO	Contenedor Docker con el modelo MuseTalk cargado de forma persistente en memoria (evita recargar pesos en cada turno); requiere una GPU

Componente	Estado	Cambio requerido
		dedicada o alquilada por horas.
Servidor de señalización WebRTC propio	NUEVO	Reemplaza la funcionalidad que en los tres proveedores comerciales viene incluida; puede construirse con librerías como aiortc (Python) o un despliegue self-hosted de LiveKit.
VirtualPatientController / Workflow / Agent	SIN CAMBIOS	Ningún cambio en la orquestación del LLM.
Media storage y grabación de 4 pistas	SIN CAMBIOS	Se sigue capturando el <video> resultante con el mismo MediaRecorder ya existente.

Es la opción con más piezas nuevas por construir (tres componentes nuevos en vez de uno o dos), lo que confirma el mayor esfuerzo de ingeniería inicial ya señalado en la sección 5.2. A cambio, es la única de las tres que no depende de un contrato ni de una cuenta de facturación con un tercero para la capa de video, y por eso se recomienda desarrollarla en paralelo desde la Fase 1B de la hoja de ruta (sección 6.4), no como una migración posterior.

8. Conclusiones

Ninguna de las tres alternativas originalmente contempladas (Tavus, Azure AI Speech Avatar, ElevenLabs) es categóricamente superior en todos los frentes: Tavus ofrece el mejor equilibrio entre facilidad de integración y catálogo de funciones, Azure ofrece la mejor integración con la arquitectura y el cumplimiento normativo ya existentes, y ElevenLabs, evaluado junto con su integración oficial de video (HeyGen LiveAvatar), sobresale en calidad de voz pero introduce un segundo proveedor en la cadena. La ampliación de la búsqueda reveló dos alternativas que cambian el análisis: Simli, por su patrón audio-to-video de bajo costo compatible con la voz ya construida, y la pila autoalojada MuseTalk, que es la única opción con costo marginal cercano a cero y control total sobre los datos. La recomendación final combina estas fortalezas en una hoja de ruta por fases en lugar de una elección única e irreversible.

9. Fuentes consultadas

Las siguientes fuentes, consultadas en agosto de 2026, respaldan las cifras de precio y latencia citadas en este informe. Los precios de mercado cambian con frecuencia; se recomienda reverificar directamente en el sitio de cada proveedor antes de la decisión final de presupuesto.

- tavus.io/pricing — Planes y precios de Tavus CVI
- tavus.io/blog/conversational-ai-pricing y [conversational-video-ai-cost-comparison](https://tavus.io/blog/conversational-video-ai-cost-comparison) — Contexto de precio y latencia de Tavus
- learn.microsoft.com — Documentación de Azure AI Speech: Text to speech avatar, Real-time synthesis for avatar, y Voice Live
- azure.microsoft.com/pricing/details/speech — Tarifas oficiales de Azure Speech/Avatar
- elevenlabs.io/blog/introducing-avatars y elevenlabs.io/docs/eleven-agents/guides/integrations/live-avatar — Alcance real de "Avatars" en ElevenLabs y su integración con HeyGen LiveAvatar
- g2.com/articles/heygen-api-pricing y fuentes secundarias de precios de HeyGen (Interactive/Streaming Avatar)
- d-id.com/ai-agents y fuentes secundarias de precios de D-ID Agents

- simli.com y verda.com/blog (Simli) — Precio y enfoque técnico de Simli
- anam.ai y anam.ai/pricing — Precio y latencia declarada de Anam
- medium.com/@ggarciabernardo — "The Live Avatar Landscape: APIs, Transport and Subjective Evaluation of 10 Leading Providers" (enero de 2026), fuente comparativa independiente usada para las calificaciones cualitativas de latencia y transporte
- github.com/TMElyralab/MuseTalk y github.com/PunithVT/ai-avatar-system — Documentación técnica y ejemplo de referencia de la pila autoalojada MuseTalk
- sync.so/blog/what-is-musetalk y lipsync.com/blog/open-source-lip-sync — Contexto comparativo de modelos abiertos de sincronización labial
- runpod.io y fuentes secundarias de precios de GPU en la nube (RunPod) — Base para la estimación de costo de cómputo de la sección 5.3

Nota final: todas las cifras de este informe son estimaciones basadas en documentación pública y análisis de terceros vigentes en agosto de 2026, no en mediciones directas ejecutadas contra las APIs de los proveedores. Deben tratarse como punto de partida para el protocolo de validación de la sección 4.4, no como cifras definitivas de contratación.